

实验 1 字串处理

1. 实验目的

- 本实验为预备实验，熟悉实验环境。
- 掌握中英文文本字串处理的基本方法。
- 掌握文字信息熵的计算方法。

2. 实验时间

2 学时。

3. 实验内容

1) 汉字字频统计

1. 给出前 100 个汉字高频字的频率统计结果；
2. 分别给出前 1、20、100、600、2000、3000 汉字的字频总和；
3. 计算汉字的熵值；

2) 英文词频统计

1. 给出前 100 个高频单词的频率统计结果；
2. 分别给出前 1、20、100、600、2000、3000 单词的词频总和；
3. 计算单词的熵值；

3) 针对不同规模语料重复上述实验；

4. 实验要求

- 1) 提交实验报告，给出详细实验过程和结果；
- 2) 提交源代码和可执行程序。